

Laboratorio 6: Análisis de Redes Sociales en YouTube

Minería de Datos, Topología de Redes Bipartitas y Análisis de Sentimiento en
Discusiones Públicas de Guatemala

CC3084 — Data Science — Semestre II – 2026

Javier Eduardo España (23361) **Angel Esteban Esquit** (23221)
Roberto Jose Barreda (23354)

Departamento de Ciencias de la Computación, Facultad de Ingeniería
Universidad del Valle de Guatemala

6 de septiembre de 2026

Resumen

Este informe presenta un estudio integral de redes sociales sobre la dinámica de participación ciudadana y consumo de contenido en YouTube en el contexto guatemalteco. A partir de una muestra de 293 videos y 406 comentarios procesados sistemáticamente, se construyó y caracterizó una red bipartita no dirigida autor-video ($N = 351$, $E = 343$), sus proyecciones unipartitas correspondientes y su estructura comunitaria mediante el algoritmo de Louvain ($Q = 0,777$). Los análisis revelan una marcada asimetría de participación dominada por la regla del 1 %, una correlación prácticamente nula ($r = 0,07$) entre visualizaciones y volumen de comentarios, y una extrema fragmentación topológica donde únicamente el 2,7 % de los autores actúa como puente inter-video. El análisis de sentimiento adaptado al español evidencia un predominio del tono negativo y de fiscalización (42,4 %), concentrado en videos sobre corrupción y gasto público. Se discuten en profundidad las implicaciones sociotécnicas, las limitaciones metodológicas de recolección y la distinción formal entre descripción, asociación e inferencia.

1. Carga, Comprensión e Integración de los Datos

1.1. Estructura de las Fuentes y Granularidad

El estudio se fundamenta en dos conjuntos de datos tabulares recolectados mediante la API de YouTube:

1. **Catálogo de Videos** (`youtube_videos.csv`): Contiene 293 registros y 20 variables. La unidad de observación es el **video individual**, y su llave primaria única e irrepetible es `video_id`. El dataset describe atributos clave como el título (`title`), canal propietario (`channel_name`, `channel_id`), número de visualizaciones observadas (`view_count`), categoría temática (`category`) y fechas de publicación.
2. **Registro de Comentarios** (`youtube_comments.csv`): Contiene 406 registros y 17 variables. La unidad de observación es el **comentario principal** (top-level comment) publicado en un video, identificado de manera unívoca por la llave primaria `comment_id`. Contiene el identificador del autor (`author_channel_id`), nombre visible (`author_name`), texto del comentario (`text`), conteos de interacción (`like_count_text`, `reply_count`) y la llave foránea `video_id`.

1.2. Modelo Relacional y Semántica de las Entidades

La relación entre las entidades del ecosistema digital se estructura jerárquica y conceptualmente de la siguiente manera:

- Un **Canal** (`channel_id`) es una entidad emisora que publica uno o varios **Videos** (`video_id`). Cada video se clasifica dentro de una **Categoría** fija y es indexado o descubierto a partir de una **Consulta de Búsqueda** (`source_query`).
- Un **Autor** (`author_channel_id`) es un usuario independiente que publica un **Comentario** (`comment_id`) en un video determinado.
- La relación es potencialmente de *muchos a muchos* entre autores y videos: un autor puede comentar en múltiples videos, y un video alberga comentarios de múltiples autores. No obstante, no existen canales directos de interacción interpersonal registrados explícitamente en el grafo.

1.3. Integración de Datos (Merge)

La unión de ambos datasets se llevó a cabo mediante una operación *left join* tomando como clave el campo `video_id`. Se verificó que los **406 comentarios (100 %)** se asociaron exitosamente con su respectivo video en el catálogo. Asimismo, se determinó que estos 406 comentarios provienen de exactamente **19 videos distintos** distribuidos en 4 canales, evidenciando que 274 videos del catálogo general no cuentan con comentarios recolectados en esta muestra.

2. Calidad, Limpieza y Preprocesamiento

2.1. Diagnóstico Inicial de Calidad

Se realizó una auditoría exhaustiva sobre la consistencia de tipos, integridad referencial y anomalías:

- **Unicidad de Llaves:** Se confirmó la total ausencia de duplicados en las llaves primarias `video_id` y `comment_id`.
- **Consistencia de Identificadores:** Se comprobó que el identificador canónico `channel_id` mapea de forma biunívoca a sus nombres visibles, y que `author_channel_id` es el único identificador persistente para los comentaristas, ya que los nombres visibles (`author_name`) y handles pueden ser modificados por el usuario.
- **Valores Atípicos:** La variable `view_count` presentó una asimetría extrema (mediana de 1,200 vistas frente a un máximo de 1.48 millones), lo que exige el uso de transformaciones logarítmicas en análisis comparativos.

2.2. Variables Problemáticas y Justificación de Tratamiento

- `viewer_rating`: Presentó un 100 % de valores faltantes (nulos). Fue descartada en su totalidad del análisis cuantitativo.
- `is_pinned`: Variable con varianza cero (constante en `False` para los 406 comentarios), por lo que no aporta poder discriminante.
- `published_text`: Expresión de tiempo relativo (p. ej., “hace 3 semanas”). Se mantuvo únicamente como referencia contextual cualitativa, descartándola para modelado de series temporales continuas.
- `source_group`: Variable con semántica dual (en `videos` representa el método de búsqueda; en `comments` clasifica el tipo de fuente). Para evitar confusiones, se utilizaron sufijos diferenciados (`source_group_video` vs. `source_group_comentario`).

2.3. Normalización y Limpieza de Variables de Texto

Para la variable `like_count_text`, almacenada como cadena con valores vacíos o formatos mixtos, se construyó una función de conversión robusta que removió caracteres no numéricos y manejó cadenas vacías asignándoles valor 0, transformándola a entero (`like_count`).

2.4. Metodología de Procesamiento de Lenguaje Natural (NLP)

Se crearon y conservaron dos columnas diferenciadas:

1. **texto_original**: Mantiene el texto íntegro para auditoría y para el análisis de sentimiento, donde la puntuación repetida, mayúsculas sostenidas y emojis aportan carga afectiva sustancial.
2. **texto_limpio**: Diseñado para la extracción de tópicos, modelado de bigramas y nubes de palabras. El pipeline aplicó: (a) conversión a minúsculas, (b) eliminación de URLs mediante expresiones regulares, (c) remoción de menciones y hashtags, (d) extracción y sustitución de emojis, (e) eliminación de signos de puntuación y números, (f) remoción de *stopwords* en español extendidas, y (g) lematización morfológica.

Métrica de Limpieza	Antes de Limpieza	Después de Limpieza	Impacto Observado
Textos vacíos	0	0	Ningún registro perdido
Textos duplicados	4	4	Se conservaron comentarios idénticos de d
Registros modificados	—	406 / 406	
Vocabulario único (tokens)	2,841	1,120	Reducción del 60.6 % en dimensio

Tabla 1: Cuantificación del efecto del preprocesamiento y limpieza de texto.

3. Análisis Exploratorio de Datos (EDA)

3.1. Resumen Estadístico Multivariado

El catálogo consolidado incluye 293 videos provenientes de 97 canales. No obstante, la participación textual activa se concentra en un subconjunto reducido: 332 autores únicos produjeron 406 comentarios en 19 videos.




Figura 1: Distribuciones estadísticas del catálogo: (a) Visualizaciones por video en escala logarítmica; (b) Distribución de comentarios por video activo; (c) Conteo de Me Gusta por comentario; (d) Correlación entre respuestas y Me Gusta ($r = 0,54$).

3.2. Concentración Extrema de la Participación

La distribución del engagement presenta una concentración de tipo Pareto pronunciada:

- El video “*Qué rico come tu diputado*” (canal *Quorum*) acumula **161 comentarios (39.7 %)** por sí solo.
- Los 3 videos más comentados reúnen **256 de los 406 comentarios (63.1 %)**.
- A nivel de canal, *Quorum* concentra **256 comentarios (63.0 %)**, seguido por el canal oficial del *Gobierno de la República de Guatemala* con **45 comentarios (11.1 %)**.




Figura 2: Concentración de la participación observada: Top videos y top canales por volumen de comentarios.

3.3. Popularidad vs. Participación (Vistas vs. Comentarios)

Se contrastó la métrica de consumo pasivo (`view_count`) con la métrica de participación activa (`comentarios`). El coeficiente de correlación de Pearson resultante fue de $r = 0,071$ ($p > 0,05$), lo que demuestra que **la visibilidad no predice la participación**. Videos con cientos de miles de reproducciones registraron escasos o nulos comentarios, mientras que contenidos de denuncia política con vistas moderadas provocaron una intensa deliberación ciudadana.

3.4. Análisis de Contenido Léxico y Bigramas

La extracción de unigramas y bigramas frecuentes en `texto_limpio` reveló un foco temático centrado en política institucional, fiscalización y corrupción pública. Los términos más dominantes fueron *pueblo*, *diputado*, *corrupto*, *pagar*, *dinero*, *guatemala* y *presidente*, mientras que los bigramas más recurrentes fueron *presidente bernardo*, *pacto corrupto* y *pueblo guatemala*.




Figura 3: Análisis de contenido textual: Nube de palabras representativa y frecuencia de los 12 bigramas más comunes en el corpus de comentarios.

3.5. Respuestas a Preguntas de Investigación

1. **¿Qué videos y canales concentran la mayor participación?** El video *Qué rico come tu diputado* (161 comentarios) y el canal *Quorum* (63% del volumen global).
2. **¿Existen audiencias compartidas entre videos o canales?** Prácticamente nulas: de 332 autores, únicamente 9 (2,7%) comentaron en más de un video, indicando que las audiencias

están fuertemente aisladas en silos temáticos.

3. **¿Qué autores funcionan como puentes?** Los 9 autores recurrentes identificados constituyen los únicos articuladores de la red.
4. **¿Los videos oficiales de gobierno reciben comentarios en la misma proporción?** No. De los 105 videos institucionales catalogados (`official_gov`), ninguno registró comentarios en esta muestra, sugiriendo posibles políticas de moderación o desactivación de interacción.
5. **¿Comentarios con más respuestas reciben más likes?** Sí, existe una correlación positiva moderada ($r = 0,54$), reflejando que los comentarios que suscitan debate tienden a ser los más valorados o visibles.
6. **¿La categoría *News & Politics* está sobrerrepresentada?** Sí: constituye el 47 % de los videos del catálogo pero concentra el 82.5 % de los comentarios observados.

4. Construcción de la Red Bipartita Autor–Video

4.1. Definición Formal del Grafo Bipartito

Se modeló la interacción como una red bipartita no dirigida $B = (V_A \cup V_V, E, W)$, donde:

- V_A es el conjunto de 332 nodos de tipo **Autor** (`author_channel_id`).
- V_V es el conjunto de 19 nodos de tipo **Video** (`video_id`).
- Una arista $e = (u, v) \in E$ existe si y solo si el autor $u \in V_A$ publicó al menos un comentario en el video $v \in V_V$.
- El peso $w(u, v) \in \mathbb{N}^+$ representa el número total de comentarios emitidos por dicho autor en ese video específico.

El grafo cuenta con $N = 351$ nodos y $E = 343$ aristas. Se comprobó matemáticamente la condición bipartita ($\chi(B) = 2$, sin ciclos de longitud impar).




Figura 4: Visualización de la red bipartita autor–video completa ($N = 351$, $E = 343$). Los nodos circulares azules representan autores; los cuadrados naranjas representan videos con etiquetas de título.

4.2. Semántica Precisa de la Arista

La arista en B representa estrictamente un acto de **co-participación en un artefacto digital común**. No debe interpretarse como una relación social directa, amistad, seguimiento o afinidad ideológica explícita entre autores.

5. Proyecciones de la Red y Topología

5.1. Proyección Autor–Autor (AA)

En la proyección autor–autor, dos autores $u_1, u_2 \in V_A$ están conectados si comentaron en al menos un video compartido. El peso de la arista equivale al número de videos compartidos:

$$w_{AA}(u_1, u_2) = \sum_{v \in V_V} A_{u_1, v} A_{u_2, v}$$

La proyección AA contiene $N = 332$ nodos y $E = 10,732$ aristas. Este número masivo de aristas es un artefacto matemático conocido de la proyección bipartita: cada video con k comentaristas genera un subgrafo completo (clique) de $\frac{k(k-1)}{2}$ aristas. Tan solo el video principal aportó 7,750 aristas (72,2 % del total). El 99.98 % de las aristas tiene peso 1; únicamente 2 pares de autores compartieron 2 videos distintos.

5.2. Proyección Video–Video (VV)

Dos videos $v_1, v_2 \in V_V$ se conectan si comparten al menos un comentarista común, con peso igual al número de autores compartidos:

$$w_{VV}(v_1, v_2) = \sum_{u \in V_A} A_{u,v_1} A_{u,v_2}$$

La red VV cuenta con $N = 19$ nodos y únicamente $E = 11$ aristas. De los 19 videos, **9 están totalmente aislados** ($d(v) = 0$), lo que corrobora la ausencia de traslape en sus audiencias.




Figura 5: Proyecciones de la red: (a) Proyección Autor–Autor ($N = 332, E = 10,732$), donde cada cúmulo refleja el clique inducido por un video; (b) Proyección Video–Video ($N = 19, E = 11$), mostrando el núcleo de 10 videos interconectados y 9 videos aislados.

5.3. Topología, Fragmentación y Cohesión

Métrica Estructural	Bipartita (B)	Proyección AA	Proyección VV
Nodos (N)	351	332	19
Aristas (E)	343	10,732	11
Densidad (ρ)	0.0056	0.1953	0.0643
Grado promedio ($\langle k \rangle$)	1.95	64.65	1.16
Componentes conexos	10	10	10 (1 comp. de 10 + 9 aislados)
Tamaño Componente Gigante	286 (81.5 %)	276 (83.1 %)	10 (52.6 %)
Transitividad / Clustering (C)	0.0000	0.9856	0.5455

Tabla 2: Resumen comparativo de métricas topológicas.

Interpretación de la Fragilidad: La red exhibe una cohesión superficial. Si se retiran los 9 autores con grado > 1 de la red AA , la componente gigante se disuelve de inmediato en 10 cúmulos disjuntos, demostrando que la conectividad global pende de un hilo extremadamente tenue de usuarios puente.

6. Detección y Caracterización de Comunidades

6.1. Algoritmo y Modularidad

Se aplicó el algoritmo de optimización de modularidad de **Louvain** con pesos sobre la red bipartita completa B . El algoritmo identificó **17 comunidades** con una modularidad sobresaliente de $Q = 0,7774$.

Detección de Comunidades Louvain sobre Red Bipartita (17 Comunidades, $Q = 0.777$)




Figura 6: Detección de comunidades de Louvain sobre la red bipartita ($Q = 0,777$). Los colores distinguen las 17 particiones detectadas; los cuadrados etiquetan los videos representativos.

6.2. Análisis de las Comunidades Principales

- **Comunidad 0** ($N = 126$, **1 video**, **125 autores**): Centrada exclusivamente en el video “*Qué rico come tu diputado*” (canal *Quorum*). Discusión intensa sobre privilegios parlamentarios y uso de fondos públicos para alimentación de legisladores.
- **Comunidad 1** ($N = 48$, **1 video**, **47 autores**): Basada en el video “*La cooptación de Walter Mazariegos en la USAC*”. Debate académico y político sobre la crisis de gobernanza universitaria y fraude electoral.
- **Comunidad 2** ($N = 32$, **3 videos**, **29 autores**): Agrupa tres videos temáticos de *Quorum* sobre movilidad urbana, telecomunicaciones y monopolios económicos (“*Caminar en una ciudad para carros*”, “*Internet: el menos malo*”, “*Arroz con pollo a la monopolio*”). Es la única comunidad que articula múltiples videos a través de comentaristas comunes recurrentes.
- **Comunidad 3** ($N = 31$, **1 video**, **30 autores**): Enfocada en la obra vial del Puente Belice II (canal *Gobierno de Guatemala*). Tono enfocado en ejecución de obra pública.

7. Nodos Centrales y Participantes Puente

7.1. Métricas de Centralidad

Se calcularon cuatro métricas fundamentales para todos los nodos sobre la componente gigante GC : Grado (k), Grado Ponderado (s), Intermediación normalizada (C_B) y PageRank (PR).

Nodo / Identificador	Tipo	Grado (k)	Betweenness (C_B)	PageRank (PR)	Rol Estructural
Qué rico come tu diputado	Video	125	0.8124	0.2845	Hub Central
Mazariegos en la USAC	Video	47	0.4210	0.1120	Hub Secundario
Inician Puente Belice II	Video	30	0.3150	0.0890	Articulador Estatal
Caminar ciudad para carros	Video	15	0.2180	0.0410	Conector Temático
@usuario_puente_01	Autor	3	0.0842	0.0078	Puente Inter-Video
@usuario_puente_02	Autor	2	0.0512	0.0054	Articulador USAC-Quor
@usuario_puente_03	Autor	2	0.0485	0.0051	Articulador Vial-Polític

Tabla 3: Principales nodos centrales y participantes puente en la componente gigante.

7.2. Puntos de Articulación y Fragilidad

Se identificaron formalmente **17 puntos de articulación** en la componente gigante: 10 videos y **7 autores articuladores**. La prueba de eliminación empírica demostró que al suprimir estos 7 autores, la componente gigante de 286 nodos se fragmenta en 8 subgrafos desconectados.

8. Análisis de Contenido y Sentimiento

8.1. Metodología y Distribución Global

Se aplicó un analizador de polaridad basado en léxico adaptado al español guatemalteco y lenguaje de redes, incorporando detección de emojis y modificadores sintácticos. La clasificación global de los 406 comentarios arrojó:

- **Negativo:** 172 comentarios (**42.4 %**)
- **Neutro:** 183 comentarios (**45.1 %**)
- **Positivo:** 51 comentarios (**12.6 %**)

El puntaje medio continuo de sentimiento se situó en $-0,17$, confirmando un sesgo emocional marcadamente adverso hacia las instituciones públicas y figuras políticas.




Figura 7: Distribución y contraste de sentimiento: (a) Proporción de polaridad por comunidad; (b) Distribución de puntaje de sentimiento compuesto ($[-1, 1]$).

8.2. Sentimiento por Comunidad y Canal

Comunidad / Canal	Total Com.	% Negativo	% Neutro	% Positivo	Puntaje Medio
C0: Qué rico come tu diputado	161	47.8 %	44.1 %	8.1 %	−0,24
C1: Mazariegos en USAC	50	46.0 %	42.0 %	12.0 %	−0,21
C2: Urbanismo y Servicios	38	26.3 %	57.9 %	15.8 %	−0,06
C3: Pte. Belice II (Gobierno)	45	35.6 %	44.4 %	20.0 %	−0,08
C4: Plan 2032 Cd. Guate	30	30.0 %	53.3 %	16.7 %	−0,07
Canal <i>Quorum</i>	256	46.5 %	43.8 %	9.8 %	−0,22
Canal <i>Gobierno de Guatemala</i>	45	35.6 %	44.4 %	20.0 %	−0,08

Tabla 4: Contraste de polaridad afectiva entre comunidades y canales clave.

Hallazgos Clave: La mayor negatividad se concentra en la Comunidad 0 (Quorum / gasto de diputados), con un léxico agresivo orientado a la indignación fiscal. En contraposición, los videos sobre infraestructura física (C3 y C4) y movilidad (C2) presentan una tasa significativamente mayor de comentarios positivos y neutro-técnicos.

9. Interpretación, Limitaciones y Conclusiones

9.1. Contextualización de la Participación en YouTube

Los hallazgos reflejan las dinámicas sociotécnicas propias de las plataformas digitales:

- **La Regla del 1 % (Lurkers vs. Creadores):** En YouTube, más del 90 % de la audiencia consume pasivamente, el 9 % interactúa mediante likes/dislikes y menos del 1 % redacta comentarios. Por ende, los 332 autores observados constituyen una vanguardia hipermotivada, motivada por la indignación moral o la militancia cívica, y no reflejan al espectador promedio.
- **Cámaras de Eco y Silos:** Salvo por un número marginal de comentaristas recurrentes, las audiencias no cruzan de un video a otro. La plataforma fomenta comunidades efímeras reunidas alrededor de eventos noticiosos específicos.

9.2. Discusión de Limitaciones Metodológicas

Se reconocen de forma explícita las siguientes limitaciones del diseño de investigación:

1. **Cobertura de Comentarios:** Se recolectaron 406 comentarios pertenecientes a 19 videos sobre un universo de 293 videos catalogados (6,5 %). Ninguna afirmación generaliza al catálogo inactivo.
2. **Sesgo de Selección por Consultas (source_query):** El muestreo dependió de términos de búsqueda centrados en política e instituciones, preseleccionando temas con alta carga de conflicto.
3. **Fechas Relativas:** La ausencia de marcas de tiempo absolutas en los comentarios impidió modelar la evolución temporal de la discusión.
4. **Instantáneas Estáticas:** Los conteos de vistas y likes corresponden a una fotografía temporal única que no captura la velocidad de interacción longitudinal.
5. **Inferencia de Relaciones Bipartitas:** La red infiere proximidad por co-ocurrencia en el video, pero no captura réplicas directas entre usuarios.
6. **Concentración Muestral:** Tres videos acaparan más del 63 % de toda la información observada.

9.3. Distinción Formal: Descripción, Asociación e Inferencia

- **Descripción:** Constatación directa de los datos (p. ej., el 42.4 % de los comentarios en este corpus es negativo).
- **Asociación:** Correlación observada en la muestra (p. ej., mayor número de respuestas se asocia con mayor número de likes, $r = 0,54$).
- **Inferencia (No permitida):** No es metodológicamente válido extrapolar estos resultados a la opinión pública de toda la sociedad guatemalteca ni a la totalidad de usuarios de YouTube.

9.4. Conclusiones Integradas

1. **Fragmentación Estructural:** La red social de debate en YouTube en Guatemala no constituye un espacio público deliberativo unificado, sino una constelación de silos temáticos aislados que dependen críticamente de menos del 3 % de autores puente para mantener conectividad global.
2. **Desconexión Consumo–Participación:** La métrica de visualizaciones (*view_count*) es ortogonal a la interacción textual ($r = 0,07$), reafirmando que el volumen de reproducciones mide alcance pasivo mientras que los comentarios miden controversia.
3. **Polaridad de Fiscalización Ciudadana:** El sentimiento predominante es negativo ($-0,17$ medio), canalizando frustración ciudadana ante temas de corrupción, opacidad y uso indebido de recursos públicos.